Clasificación de hojas de café sanas, con roya y con ojo de gallo en fotos de otros países: ResNet50 y ViT-B/16 entrenados con fotos de Saposoa (Perú)

Andhersson M. Salazar F.
UNI, Lima, Perú
andhersson.salazar.f@uni.pe
ORCID: 0009-0006-4517-5666

Alexander A. Chavez C.
UNI, Lima, Perú
alexander.chavez.c@uni.pe
ORCID: 0009-0000-0956-9082

Alex R. Pomazón S.
UNI, Lima, Perú
alex.pomazon.s@uni.pe
ORCID: 0009-0004-8514-1546

Christian A. Urviola G.
UNI, Lima, Perú
christian.urviola.g@uni.pe
ORCID: 0000-0003-4621-7128

***Resumen*—La roya del café causa pérdidas importantes en América Latina. Un modelo que la reconozca en fotos de hojas puede ayudar al productor, pero solo si funciona con hojas de otras fincas y no únicamente con las fotos con que se entrenó. En este trabajo entrenamos ResNet50 y ViT-B/16, dos redes preentrenadas en ImageNet, con 1 498 fotos de hojas de Saposoa (Perú) de tres clases: sana, roya y ojo de gallo. Luego las probamos, sin volver a entrenarlas, con fotos de campo de Ecuador (RoCoLe, 1 312) y de Uganda (1 117). Antes de entrenar eliminamos las fotos repetidas y separamos las de Saposoa por grupos de fotos consecutivas. Comparamos tres tipos de aumento de datos, uno de ellos cambia el fondo de la foto, y repetimos cada prueba con tres semillas. En Saposoa todos los modelos llegan a un F1 de 0.99 o más, lo mismo que un modelo simple basado en colores. En Ecuador, ViT-B/16 obtiene un AUC de 0.920±0.009, frente a 0.858±0.006 de ResNet50 y 0.750 del mejor modelo simple. En Uganda ningún modelo supera con claridad al modelo simple (0.767). También comprobamos que los modelos aprenden a reconocer la clase mirando solo el fondo de Saposoa; cambiar el fondo al entrenar corrige eso, pero no mejora los resultados en otros países. Lo que más falla es el reconocimiento de las hojas sanas de campo, que el modelo suele tomar por enfermas. Todo el entrenamiento tomó 1.12 horas de GPU.**

***Palabras clave*—aprendizaje profundo, roya del café, cambio de dominio, Vision Transformer, aprendizaje por atajos, Grad-CAM**

I. Introducción

La roya del café (*Hemileia vastatrix*) es la enfermedad que más daña las hojas de este cultivo. Entre 2008 y 2013 hizo caer la producción en Colombia y Centroamérica y afectó a cientos de miles de familias que viven del café [1]. Para controlarla hay que detectarla a tiempo, y eso hoy depende de que un técnico revise las plantas, algo difícil en fincas pequeñas y alejadas. Una aplicación que reconozca la enfermedad con la foto de un celular sería de mucha ayuda, siempre que funcione con las hojas de la finca donde se usa.

Ahí está el problema. Los modelos entrenados con fotos tomadas en condiciones controladas suelen acertar casi siempre en su propio conjunto de prueba, pero fallan bastante con fotos de campo [2]. Además, si cada enfermedad se fotografió con un fondo distinto, la red puede aprender a reconocer el fondo en vez de la enfermedad [3].

En este trabajo el modelo recibe la foto de una hoja de café y debe decir si está sana, si tiene roya o si tiene ojo de gallo (*Mycena citricolor*). Lo entrenamos solo con fotos de Saposoa (San Martín, Perú) y lo evaluamos con fotos de campo de Ecuador y de Uganda que nunca vio. Lo que buscamos es que separe bien las hojas con roya de las sanas en esas fotos.

Usamos aprendizaje profundo porque las lesiones de roya y de ojo de gallo se diferencian por su forma, su color y su textura, y las redes preentrenadas reconocen ese tipo de detalles mejor que las medidas de color hechas a mano (lo comprobamos con los modelos de comparación). Elegimos dos arquitecturas vistas en el curso: una red convolucional, ResNet50 [4], y un Transformer para imágenes, ViT-B/16 [5]. Queríamos ver si el Transformer se adapta mejor a fotos de otro lugar, como se ha reportado en otros cultivos [6]. A diferencia de los ejemplos del curso, que evalúan con fotos del mismo conjunto, aquí medimos qué pasa con fotos de otros países y comprobamos si el modelo se fija en el fondo.

Los aportes de este trabajo son:

- Una evaluación con fotos de otros países: entrenamos con fotos de Saposoa y probamos con fotos de Ecuador y Uganda, después de unificar las etiquetas, quitar fotos repetidas y separar los datos sin que se filtren fotos de entrenamiento a la prueba.
- Una comparación entre ResNet50 y ViT-B/16 con tres tipos de aumento de datos, entre ellos uno que cambia el fondo de la foto, con tres semillas cada uno.
- Una prueba que cambia el fondo de las fotos para ver si el modelo depende de él, junto con mapas Grad-CAM y un análisis de los errores.

- Un repositorio que permite repetir todo en menos de 1.2 horas de GPU, con los pesos de los modelos y un notebook de demostración.

En la Sección II revisamos trabajos anteriores, en la Sección III describimos los datos y los modelos, en la Sección IV presentamos los resultados, en la Sección V los discutimos y en la Sección VI cerramos con las conclusiones.

II. Trabajos relacionados

II-A. Arquitecturas

ResNet [4] agregó conexiones que saltan capas, lo que permitió entrenar redes convolucionales muy profundas. Desde entonces es una de las redes más usadas como punto de partida para tareas de imágenes. ViT [5] toma otra idea: corta la imagen en parches de 16×16 píxeles y los trata como las palabras de un texto, usando un Transformer. Cuando se preentrena con muchas imágenes iguala o supera a las redes convolucionales, y desde la primera capa puede relacionar partes de la imagen que están lejos entre sí. En este trabajo usamos las dos tal como fueron publicadas.

II-B. Enfermedades de plantas

Mohanty et al. [2] entrenaron redes con el conjunto PlantVillage y llegaron a 99.35 % de exactitud, pero al probar con fotos tomadas en otras condiciones la exactitud bajó a 31 %. En café, Esgario et al. [7] clasificaron enfermedades y estimaron su severidad en hojas de Brasil, evaluando con fotos del mismo conjunto. Los autores del conjunto de Saposoa [8] usaron ResNet18 junto con una SVM y obtuvieron 0.974 de exactitud separando las fotos al azar, sin probar con fotos de otros lugares. Benabbas et al. [6] encontraron que los ViT pierden menos que las redes convolucionales al pasar de fotos de laboratorio a fotos de campo. Nosotros llevamos esa pregunta al café, con dos conjuntos de otros países y cuidando que las fotos repetidas no inflen los resultados.

II-C. Atajos e interpretación

Geirhos et al. [3] llaman *aprendizaje por atajos* a lo que pasa cuando una red aprende una regla que le sirve en los datos de entrenamiento, como fijarse en el fondo, pero que no es la que se buscaba y deja de servir con otros datos. Grad-CAM [9] dibuja un mapa con las zonas de la imagen que más influyeron en la decisión. Como ese mapa no prueba que el modelo dependa de esas zonas, además de usarlo cambiamos el fondo de las fotos y medimos cómo cambia la respuesta.

III. Metodología

III-A. Datos

Los tres conjuntos son públicos y tienen licencia CC BY 4.0. El de **Saposoa** [10] trae 1 499 fotos de hojas de café arábica sobre un fondo claro, unas 500 por clase. **RoCoLe** [11] tiene 1 560 fotos de hojas de café robusta tomadas en plantas de Ecuador, con vegetación de fondo. El de **Uganda** [12] tiene 3 322 fotos tomadas de cerca en el campo, donde la hoja ocupa casi todo el cuadro.

Tabla I
Fotos de cada conjunto después de la limpieza

Conjunto	Uso	Sana	Roya	Ojo de g.	Total
Saposoa	Entrenamiento	349	349	350	1 048
	Validación	80	80	80	240
	Prueba	70	70	70	210
RoCoLe	Prueba externa	750	562	–	1 312
Uganda	Prueba externa	569	548	–	1 117

Para que las etiquetas coincidieran, en RoCoLe juntamos los cuatro niveles de roya en una sola clase y en Uganda usamos las carpetas de hojas sanas y de roya. Dejamos fuera las clases que no existen en Saposoa: ácaro rojo en RoCoLe y phoma en Uganda. Ninguno de los dos conjuntos externos tiene ojo de gallo.

Luego quitamos las fotos que no se podían abrir y las copias exactas. Para las fotos casi iguales comparamos cada par usando la representación que da ResNet50 de cada imagen. Revisando ejemplos fijamos un límite de similitud para cada conjunto (0.975 en RoCoLe y 0.93 en Uganda); de cada grupo de fotos casi iguales dejamos solo una, y si el grupo tenía etiquetas distintas lo sacamos completo. En Uganda esto eliminó dos tercios de las fotos, casi todas copias del mismo recorte con otro brillo o posición. La Fig. 1 muestra tres casos que encontramos, y la Tabla I, lo que quedó después de la limpieza.

En Saposoa a veces la misma hoja aparece en dos fotos seguidas. Si una queda en entrenamiento y la otra en prueba, el resultado de la prueba sale mejor de lo que es. Como la similitud no bastaba para detectar estos casos, ordenamos las fotos de cada clase según el orden en que se tomaron, las juntamos en grupos de 10 seguidas y repartimos los grupos completos al azar: 70 % para entrenamiento, 16 % para validación y 14 % para prueba. Luego medimos, para cada foto de validación y de prueba, cuánto se parece a la foto más parecida de entrenamiento. Con nuestro reparto, el 6.9 % de las fotos tiene una muy parecida (similitud de 0.95 o más); con un reparto al azar foto por foto serían el 8.2 %. El riesgo era bajo y así quedó un poco más bajo. Las fotos de Ecuador y Uganda solo se usaron para la prueba final y no influyeron en ninguna decisión del entrenamiento.

Todas las fotos se redujeron a 320 píxeles en su lado más corto. Al evaluar, se ajustan a 224 píxeles y se toma el cuadrado central de 224×224. La Fig. 2 muestra un ejemplo de cada conjunto.

III-B. Aumento de datos

Durante el entrenamiento, cada foto se modifica un poco cada vez que el modelo la ve, para que aprenda a reconocer la hoja aunque cambie la luz, el tamaño o la posición. Probamos tres versiones. En la **básica** solo recortamos entre el 70 y el 100 % de la foto y la volteamos de izquierda a derecha. En la **fuerte** el recorte va del 40 al 100 %, volteamos en ambos sentidos, giramos hasta 20°, cambiamos el brillo, el contraste y la saturación hasta en 40 %, movemos un poco el tono y a



Figura 1. Fotos casi iguales encontradas al comparar las imágenes. A la izquierda, dos tomas seguidas de la misma hoja en Saposoa, que motivaron la partición por bloques. Al centro, el mismo recorte guardado dos veces en Uganda. A la derecha, el mismo recorte etiquetado como phoma y como roya; en estos casos se excluyeron las dos fotos.



Figura 2. Un ejemplo de cada conjunto y clase, tomados de las fotos de prueba. En Saposoa la hoja está sola sobre un fondo claro; en RoCoLe está en la planta, con vegetación detrás; en Uganda es un recorte cercano donde la hoja llena el cuadro.

veces desenfocamos la imagen. En la tercera, **fuerte + fondo**, además cambiamos el fondo de la foto en 8 de cada 10 casos por un color liso o una mancha de colores al azar (Fig. 3).

Para cambiar el fondo hace falta saber qué píxeles son de la hoja. Como no teníamos esa información, la calculamos: el borde de cada foto de Saposoa es casi todo fondo, así que marcamos como hoja los píxeles cuyo color se aleja bastante del color del borde, limpiamos los puntos sueltos y rellenamos la silueta. Con esa máscara m la foto nueva es

$$\tilde{x} = \alpha \odot x + (1 - \alpha) \odot b, \tag{1}$$

donde x es la foto original, b el fondo elegido al azar y α la máscara con el borde suavizado, para que no quede un corte brusco. Si la máscara salía demasiado chica o demasiado grande, no cambiábamos el fondo de esa foto. Las 1 048 fotos de entrenamiento obtuvieron una máscara válida.

III-C. Modelos

Los dos modelos empiezan con los pesos aprendidos en ImageNet. Les cambiamos la última capa por una con tres salidas, una por clase, y luego entrenamos todas las capas con nuestras fotos. La Fig. 4 muestra cómo procesa cada uno la foto.

ResNet50 (23.5 millones de parámetros) pasa la foto de $224 \times 224 \times 3$ por una primera convolución, que la deja en 112×112, y por un *max pooling*, que la baja a 56×56. Siguen cuatro etapas de bloques residuales; desde la segunda, cada etapa reduce el tamaño a la mitad y aumenta los canales, hasta llegar a $7 \times 7 \times 2048$. Luego promedia cada canal y obtiene un vector de 2 048 valores.

ViT-B/16 (85.8 millones de parámetros) corta la foto en 196 parches de 16×16 píxeles y convierte cada uno en un vector de 768 valores. A esa lista le agrega un vector especial, llamado [CLS], que al final resume toda la imagen. Los 197 vectores pasan por 12 bloques de Transformer, y en cada bloque cada parche puede tomar información de todos los demás.

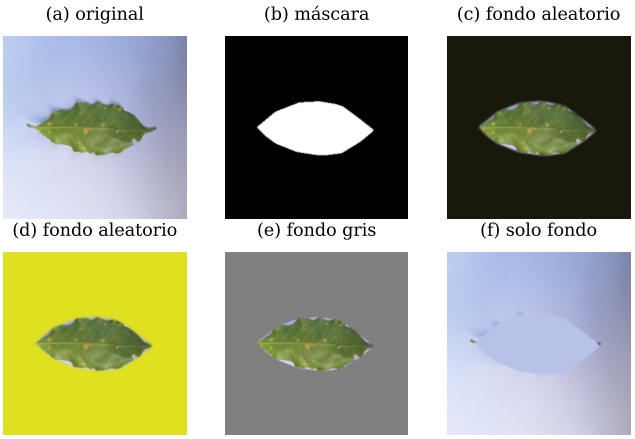


Figura 3. La máscara de la hoja y sus usos. De (a) a (d): el aumento que cambia el fondo. (e) y (f): las versiones usadas en la prueba de fondo de la Sección IV-C.

En los dos casos, una capa lineal convierte el vector final en tres valores, y la función softmax los convierte en probabilidades.

III-D. Función de pérdida y puntaje externo

Sea $p_\theta(c \mid x)$ la probabilidad que el modelo, con parámetros θ, le da a la clase c para la foto x. Durante el entrenamiento

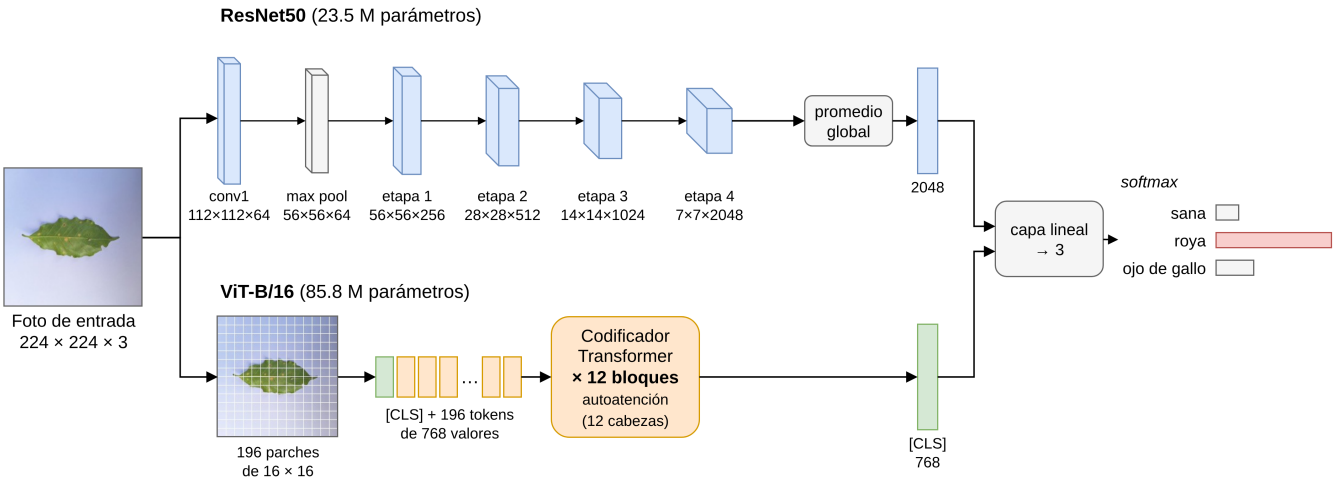


Figura 4. Cómo procesan la foto los dos modelos. Arriba, ResNet50 reduce la imagen con una primera convolución, un *max pooling* y cuatro etapas de bloques residuales, hasta un vector de 2 048 valores. Abajo, ViT-B/16 corta la imagen en 196 parches y los procesa con 12 bloques de Transformer. Los dos terminan en una capa lineal con tres salidas. Se entrenan solo con Saposoa, partiendo de los pesos de ImageNet.

buscamos los parámetros que minimizan la entropía cruzada:

$$\mathcal{L}(\theta) = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{3} y_{i,c}\,\log p_\theta(c \mid x_i), \tag{2}$$

donde N es el número de fotos y $y_{i,c}$ vale 1 si la foto i es de la clase c y 0 si no. Como las tres clases tienen casi la misma cantidad de fotos, no hizo falta darles pesos distintos.

En ViT, la parte central es la autoatención. Cada parche genera tres vectores, Q, K y V, y la salida es $\mathrm{softmax}(QK^\top/\sqrt{d_k})\,V$ con $d_k = 64$. Dicho de forma simple, cada parche decide cuánto tomar de cada uno de los demás según qué tanto se parecen.

En Ecuador y Uganda solo hay hojas sanas y con roya, así que para esas fotos comparamos solo esas dos probabilidades:

$$s(x) = \frac{p_\theta(\text{roya} \mid x)}{p_\theta(\text{roya} \mid x) + p_\theta(\text{sana} \mid x)}. \tag{3}$$

Si $s(x)$ es 0.5 o más, la foto se cuenta como roya. Aparte anotamos cuántas fotos habrían ido a ojo de gallo si el modelo eligiera libremente entre las tres clases.

III-E. Entrenamiento y métricas

Entrenamos con AdamW durante 15 épocas, con lotes de 32 fotos y una tasa de aprendizaje que empieza en 10^{-4} para ResNet50 y en 3×10^{-5} para ViT-B/16, y baja poco a poco hasta cero. A ViT le dimos una tasa menor porque con tasas altas su entrenamiento se vuelve inestable. Para evitar que los pesos crezcan demasiado usamos un decaimiento de pesos de 0.05. De cada entrenamiento nos quedamos con la época que tuvo la menor pérdida en validación; el F1 de validación llegaba a 1.0 muy pronto y ya no ayudaba a elegir. Cada configuración se entrenó tres veces, con las semillas 0, 1 y 2, que controlan el orden de las fotos, los aumentos y los valores iniciales de la última capa. Todos estos valores se fijaron antes de ver los resultados en Ecuador y Uganda.

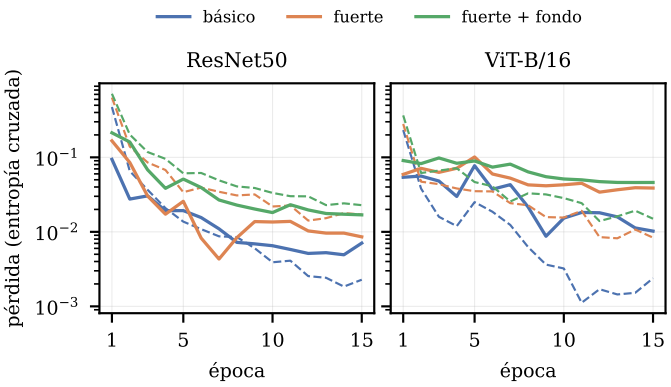


Figura 5. Pérdida por época, promedio de 3 semillas, en escala logarítmica. Línea continua: validación (Saposoa). Línea discontinua: entrenamiento.

La Fig. 5 muestra cómo bajó la pérdida durante el entrenamiento, en promedio de las tres semillas. En ResNet50 la pérdida de validación cae casi toda en las primeras cinco épocas; en ViT-B/16 empieza más baja y baja más despacio. En ningún caso vuelve a subir de forma clara al final, así que 15 épocas fueron suficientes y no vimos un sobreajuste marcado. La mejor época quedó entre la 7 y la 15, según la corrida. Con el aumento fuerte y con el cambio de fondo la pérdida de entrenamiento queda más alta, porque cada foto llega más modificada. Los modelos entrenados con cambio de fondo terminan además con una pérdida de validación algo mayor, lo que tiene sentido: se validan con fotos que conservan su fondo original.

Para comparar usamos modelos simples (líneas base) que trabajan con tres tipos de datos: un resumen del color y la textura de toda la foto; el color del borde de la foto, que en Saposoa es casi solo fondo; y el vector de ResNet50 sin entrenar con nuestras fotos. Con cada uno entrenamos una

regresión logística y un random forest.

En Saposoa medimos el F1 macro, que promedia el acierto de las tres clases. En Ecuador y Uganda la medida principal es el AUC del puntaje $s(x)$: indica con qué frecuencia una hoja con roya recibe un puntaje más alto que una sana. Vale 0.5 si el modelo adivina y 1 si ordena todas bien, y no depende de dónde se ponga el corte de 0.5. También damos el F1 con ese corte. Todos los números son el promedio y la desviación estándar de las tres semillas. Usamos Google Colab con una GPU NVIDIA T4, PyTorch 2.11 y torchvision 0.26.

IV. Resultados

IV-A. Comparación con las líneas base

En Saposoa todos los modelos aciertan casi siempre (Tabla II). Un random forest con el color y la textura de la foto llega a un F1 de 0.981, y las redes entrenadas, a entre 0.990 y 1.000. Más llamativo es que el modelo que solo mira el borde de la foto llega a 0.791, cuando adivinando se obtendría 0.33. El fondo de Saposoa ya da pistas sobre la clase, así que acertar en Saposoa no prueba que el modelo reconozca la enfermedad.

Con fotos de otros países los resultados cambian mucho. En Ecuador, ViT-B/16 obtiene un AUC entre 0.909 y 0.920, ResNet50 entre 0.831 y 0.858 y el mejor modelo simple 0.750. Las diferencias entre semillas son de apenas 0.01, así que este es el resultado más firme del trabajo. En Uganda ningún modelo supera con claridad al modelo simple (0.767): los promedios van de 0.717 a 0.779 y cambian entre 0.05 y 0.14 de una semilla a otra, más que la diferencia entre modelos.

El F1 en las fotos externas es bajo para todos, entre 0.40 y 0.70, aunque el AUC sea alto. Esto pasa porque el modelo ordena bien las hojas, pero el corte de 0.5 queda mal ubicado en las fotos nuevas, como se ve en la Sección IV-C. Por eso comparamos los modelos con el AUC.

Las líneas base muestran lo mismo de otra forma. La regresión logística sobre el vector de ResNet50 acierta todas las fotos de Saposoa (F1 de 1.000), pero en Ecuador llega a un AUC de 0.708 y en Uganda a 0.459, por debajo del azar. Acertar en Saposoa no dice casi nada sobre lo que pasará con fotos de otro lugar.

IV-B. Ablación

En la Tabla II cambiamos una cosa a la vez: el modelo o el aumento de datos. Con el mismo aumento, ViT-B/16 supera a ResNet50 en Ecuador por 0.06 a 0.08 de AUC, bastante más que la variación entre semillas. Pasar del aumento básico al fuerte mejora a los dos modelos en Ecuador (ResNet50 de 0.831 a 0.858 y ViT de 0.909 a 0.920) y reduce las fotos que terminan en ojo de gallo (en ResNet50, de 91 a 71 %). Agregar el cambio de fondo no mejora nada en Ecuador. En Uganda sube un poco en ViT (de 0.750 a 0.777) y baja en ResNet50 (de 0.779 a 0.728), pero en los dos casos la diferencia es menor que la variación entre semillas. La mejora viene entonces del tipo de modelo y del aumento fuerte. Más abajo veremos que el cambio de fondo sí logra lo que buscaba, aunque eso no se note en las fotos de otros países.

IV-C. Interpretación y análisis de errores

Grad-CAM: Para cada modelo de la semilla 0 calculamos el mapa Grad-CAM [9] de la clase que predijo:

$$L^c = \mathrm{ReLU}\Big(\sum_k \alpha_k^c A^k\Big), \qquad \alpha_k^c = \frac{1}{Z}\sum_{i,j}\frac{\partial y^c}{\partial A_{ij}^k}. \tag{4}$$

Aquí A^k es el mapa k de la última capa que todavía conserva la forma de la imagen (7×7 en ResNet50 y 14×14 en ViT), y^c es la salida de la clase c y Z es el número de posiciones del mapa. Cada mapa pesa más cuanto más cambia la salida al cambiarlo.

Para saber si el modelo mira la hoja medimos qué parte del mapa cae dentro de la máscara de la hoja en las 210 fotos de prueba de Saposoa. La hoja ocupa en promedio el 17.9 % de la foto, así que un mapa al azar pondría ahí cerca del 18 %. Dividimos la parte que cae en la hoja entre ese 17.9 % y llamamos al resultado *concentración*: vale 1 si el mapa es como uno al azar. En ResNet50 entre el 66 y el 73 % del mapa cae en la hoja, una concentración de 3.7 a 4.1 (Tabla III). En ViT la concentración queda entre 0.86 y 1.05 y los mapas se ven dispersos (Fig. 6). Eso no quiere decir que ViT mire el fondo. En su último bloque cada parche ya mezcló información de toda la imagen, y Grad-CAM no logra separar qué parte vino de dónde. Por eso hicimos una prueba directa.

Prueba de fondo: A cada modelo de la semilla 0 le mostramos tres versiones de las 210 fotos de prueba de Saposoa (Fig. 3): la original, la hoja con el fondo pintado de gris y solo el fondo, con la hoja borrada y rellenada con el color del fondo. Si el modelo acierta mucho más que al azar viendo solo el fondo, quiere decir que aprendió a reconocer la clase por el fondo.

Los resultados están en la Tabla III. Los modelos entrenados sin cambio de fondo sí aprendieron a usarlo: ResNet50 con aumento básico acierta con un F1 de 0.82 sin ver la hoja, y los demás quedan entre 0.50 y 0.59. ViT también lo hace, cosa que Grad-CAM no dejaba ver. Aun así, cuando la hoja está presente, deciden por ella: con el fondo gris todos mantienen un F1 de 0.97 o más. Los dos modelos entrenados con cambio de fondo bajan a 0.24 y 0.26 cuando solo ven el fondo, es decir, ya no sacan nada de él, y siguen acertando igual con las fotos originales.

Errores en las fotos de campo: La Tabla IV muestra a qué clase fue cada foto de Ecuador y Uganda, sumando las tres semillas. Se ven dos cosas. La primera es que el ojo de gallo termina recibiendo de todo: no solo las hojas con roya, también muchas sanas (89 % de las sanas de Ecuador con ResNet50 básico). La segunda es que casi ninguna hoja sana de campo se reconoce como sana, solo entre el 2 y el 18 %. Una hoja sana en la planta tiene polvo, sombras y mordidas de insectos, y se parece poco a las hojas sanas y limpias de Saposoa.

Si comparamos solo roya contra sana, casi todos los errores van hacia el mismo lado. Con ViT-B/16 fuerte + fondo (semilla 0), 594 hojas sanas de Ecuador se clasificaron como roya y solo 8 con roya como sanas; en Uganda fueron 549 y 0. El

Tabla II
RESULTADOS EN LA PRUEBA DE SAPOSOA Y EN LAS PRUEBAS EXTERNAS (PROMEDIO ± DESVIACIÓN ESTÁNDAR DE 3 SEMILLAS)

		Saposoa	AUC roya frente a sana		F1 macro externo		% enviado a ojo de gallo	
Modelo	Aumento	F1 macro	RoCoLe	Uganda	RoCoLe	Uganda	RoCoLe	Uganda
Color + textura, RL	–	0.957	0.584	0.648	0.547	0.647	33	75
Color + textura, RF	–	0.981±0.000	0.587±0.012	0.753±0.012	0.320±0.008	0.526±0.033	96	57
Solo borde, RL	–	0.787	0.552	0.522	0.482	0.475	81	59
Solo borde, RF	–	0.791±0.007	0.534±0.003	0.291±0.009	0.428±0.026	0.390±0.015	82	56
ResNet50 sin ajustar, RL	–	1.000	0.708	0.459	0.622	0.460	41	58
ResNet50 sin ajustar, RF	–	0.981±0.005	0.750±0.045	**0.767±0.014**	0.304±0.001	0.339±0.008	30	74
ResNet50	básico	1.000±0.000	0.831±0.013	0.743±0.142	0.696±0.103	0.662±0.148	91	98
	fuerte	1.000±0.000	0.858±0.006	**0.779±0.063**	0.468±0.026	0.533±0.059	71	66
	fuerte + fondo	0.995±0.005	0.858±0.033	0.728±0.064	0.625±0.092	0.492±0.072	67	47
ViT-B/16	básico	1.000±0.000	0.909±0.011	0.717±0.054	0.494±0.050	0.400±0.010	53	54
	fuerte	0.994±0.007	**0.920±0.009**	0.750±0.052	0.460±0.021	0.408±0.047	40	55
	fuerte + fondo	0.990±0.008	**0.920±0.009**	**0.777±0.060**	0.587±0.082	0.439±0.072	53	64

RL: regresión logística (da siempre el mismo resultado, por eso no tiene desviación). RF: random forest.

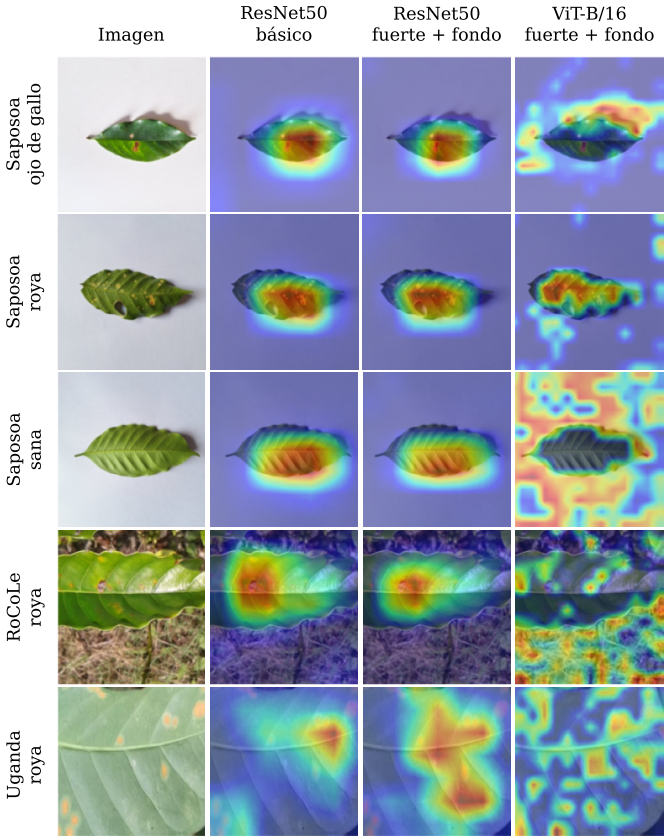


Figura 6. Mapas Grad-CAM de la clase predicha (semilla 0). ResNet50 se fija en la hoja y en las manchas; en ViT-B/16 el mapa queda disperso. En las fotos de campo, ResNet50 marca las manchas de roya pero responde ojo de gallo.

modelo encuentra casi toda la roya, pero da muchas falsas alarmas. Eso explica por qué el AUC es alto y el F1 bajo: en las fotos de campo los puntajes de todas las hojas suben hacia roya, y con el corte en 0.5 muchas sanas quedan del lado equivocado.

La Fig. 7 muestra algunos de los errores en los que el

Tabla III
PRUEBA DE FONDO Y GRAD-CAM EN LAS FOTOS DE PRUEBA DE SAPOSOA (SEMILLA 0)

		F1 macro			Grad-CAM
Modelo	Aumento	Original	Fondo gris	Solo fondo	concentr.
ResNet50	básico	1.000	0.986	**0.821**	3.69
	fuerte	1.000	0.986	0.590	4.04
	+ fondo	0.990	1.000	**0.242**	4.09
ViT-B/16	básico	1.000	1.000	0.539	0.86
	fuerte	1.000	0.971	0.501	1.01
	+ fondo	0.995	0.995	**0.263**	1.05

Adivinando, el F1 sería 0.33. Concentración 1: igual que un mapa al azar.

Tabla IV
CLASE ASIGNADA A LAS FOTOS DE CAMPO, EN % DE CADA CLASE REAL (SUMA DE 3 SEMILLAS): OJO DE GALLO / ROYA / SANA

		RoCoLe (Ecuador)		Uganda	
Modelo	Aumento	sana	roya	sana	roya
ResNet50	básico	89/1/11	95/4/1	95/3/2	100/0/0
	fuerte	70/25/6	74/26/0	64/25/11	67/31/1
	+ fondo	63/22/15	72/27/1	54/35/12	41/56/4
ViT-B/16	básico	48/40/12	59/40/1	43/53/3	65/35/0
	fuerte	37/52/11	44/56/0	51/46/3	59/41/0
	+ fondo	49/33/18	58/41/1	66/32/2	62/38/0

modelo estaba más seguro. En la foto de Uganda la hoja se ve sana y el modelo le da 0.99 de probabilidad al ojo de gallo. En las de Ecuador hay hojas sanas con brillos y sombras que el modelo toma por roya o por ojo de gallo, y una hoja con roya en la que las manchas apenas se ven y que pasa como sana.

IV-D. Costo computacional

Hicimos 18 entrenamientos (2 modelos, 3 aumentos y 3 semillas) que en total tomaron 67 minutos en una GPU T4, es decir, 1.12 horas. Cada entrenamiento de ResNet50 tardó 1.6 minutos con el aumento básico, 2.6 con el fuerte y 4.8

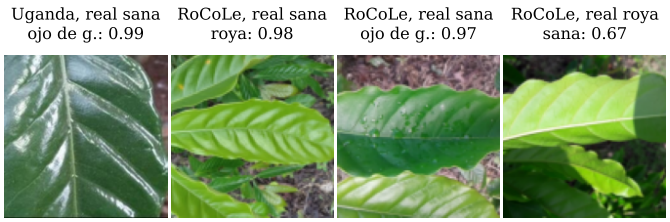


Figura 7. Errores de ViT-B/16 fuerte + fondo (semilla 0) en fotos de campo, con la clase que eligió y su probabilidad.

con el cambio de fondo; los de ViT-B/16 tardaron 3.6, 4.0 y 5.8 minutos. El cambio de fondo es el más lento porque la máscara y la mezcla se calculan en el procesador y no en la GPU. La T4 consume como máximo 70 W, así que el gasto de la GPU no pasó de 0.08 kWh. A esto se suman algunos minutos para descargar y limpiar los datos, las líneas base, Grad-CAM y la prueba de fondo, casi todo en el procesador.

V. Discusión

V-A. *Por qué ViT funcionó mejor en Ecuador*

Con los mismos datos, el mismo preentrenamiento y el mismo aumento, ViT-B/16 ordenó mejor las fotos de Ecuador que ResNet50, igual que lo reportado por Benabbas et al. [6]. Una posible razón es que ViT relaciona toda la hoja desde el comienzo, mientras que una red convolucional arma su decisión a partir de detalles de textura locales, que cambian más con la cámara, la luz y el fondo. No podemos separar este efecto del tamaño, porque ViT tiene casi cuatro veces más parámetros.

V-B. *El fondo y la caída fuera de Saposoa*

La prueba de fondo confirma lo que advierten Geirhos et al. [3]: un modelo entrenado sin cambio de fondo puede acertar la clase con F1 de hasta 0.82 mirando solo el fondo de Saposoa. Cambiar el fondo durante el entrenamiento corrige eso, pero el AUC en Ecuador queda igual (0.920 en ViT con y sin el cambio). La caída en las fotos de otros países no viene del fondo, viene de cómo se ven las hojas. En Saposoa una hoja sana está limpia y sola; en el campo tiene polvo, sombras, brillos y daños, y el modelo la confunde con una enferma. A eso se suma que las hojas de RoCoLe son de café robusta y las de Saposoa de café arábica.

También pesa que en Ecuador y Uganda no haya ojo de gallo. El modelo tiene que elegir siempre una de las tres clases, y cuando la foto no se parece a nada de Saposoa, muchas veces elige ojo de gallo. No tiene forma de responder que no está seguro.

Uganda resultó difícil para todos por tres razones: las fotos son recortes muy cercanos y la hoja se ve a otra escala, varias están borrosas y dos tercios del conjunto eran copias, lo que hace pensar que sus autores ya habían aplicado aumento de datos. Con tanta variación entre semillas no se puede decir qué modelo es mejor en ese conjunto.

V-C. *Comparación con otros trabajos*

La exactitud de 0.974 que reportan Santa-María y Rodríguez [8], con un reparto de fotos al azar, coincide con nuestro F1 de 0.99 a 1.00 en Saposoa: dentro de ese conjunto el problema es sencillo. Nuestro aporte es mostrar lo que pasa fuera de él. La caída que encontramos va en la misma dirección que la de Mohanty et al. [2], que pasaron de 99 a 31 % de exactitud.

V-D. *Limitaciones*

Todas las fotos de entrenamiento vienen de una sola zona y se tomaron de la misma manera. Tres semillas no alcanzan para separar diferencias pequeñas, sobre todo en Uganda. La prueba de fondo y Grad-CAM se hicieron solo con la semilla 0, y en la versión con solo fondo queda la silueta de la hoja y su sombra, así que parte del 0.82 de ResNet50 básico podría venir de la forma de la hoja. La máscara se calcula con reglas simples y a veces deja un poco de fondo o de sombra. Grad-CAM no sirve bien para explicar a ViT. El modelo elige siempre una de las tres clases con las que se entrenó, así que una hoja con otra enfermedad, como phoma o ácaro rojo, o una foto que ni siquiera es de una hoja, terminaría como sana, con roya o con ojo de gallo. No lo medimos, porque esas fotos se dejaron fuera de la prueba. Las etiquetas de Ecuador y Uganda las pusieron otras personas con criterios que no podemos revisar; en Uganda encontramos el mismo recorte marcado como roya y como phoma. El entrenamiento en GPU tampoco es del todo repetible. Christian Urviola volvió a entrenar ViT-B/16 con cambio de fondo y semilla 0 en otra GPU (RTX 5050): dos corridas dieron un AUC de 0.936 y 0.859 en Ecuador, y con el modo determinista de PyTorch las dos dieron 0.909. Una sola corrida puede moverse bastante, por eso reportamos el promedio de tres semillas. En nuestras 18 corridas en la T4, la peor de ViT-B/16 en Ecuador (0.902) quedó por encima de la mejor de ResNet50 (0.888). Por último, no ajustamos el corte de decisión con fotos de campo, porque hacerlo con las fotos de prueba sería usar las respuestas para calibrar el modelo.

V-E. *Sesgos, riesgos y uso responsable*

El modelo aprendió cómo se ven las hojas de Saposoa sobre un fondo claro, y ese es su principal sesgo. Si se usara tal cual en el campo encontraría casi toda la roya, pero también marcaría como enfermas muchas hojas sanas. Una falsa alarma puede llevar a aplicar fungicida sin necesidad, lo que cuesta dinero y daña el ambiente; una roya que no se detecta deja avanzar la enfermedad. Por eso este modelo no debería usarse para decidir un tratamiento sin que lo confirme un técnico, y antes de llevarlo a otra zona habría que probarlo con fotos etiquetadas de esa zona. Los datos no tienen información de personas.

VI. Conclusiones

Un modelo entrenado con fotos de un solo lugar puede parecer perfecto en su propia prueba y fallar en otro país. En Saposoa, ResNet50 y ViT-B/16 lograron un F1 de 0.99 a

1.00, igual que un modelo que solo mira colores. Con fotos de campo de Ecuador, ViT-B/16 con aumento fuerte separó bien las hojas con roya de las sanas (AUC de 0.920), mejor que ResNet50 y que los modelos simples. En Uganda ninguno se distinguió con claridad del modelo simple. Comprobamos que los modelos aprenden a usar el fondo de Saposoa y que cambiar el fondo al entrenar lo evita, pero esto no mejora los resultados fuera de Saposoa. Lo que falla es el reconocimiento de las hojas sanas de campo y la falta de una opción para decir "no estoy seguro".

Como siguientes pasos proponemos ajustar el corte de decisión con unas pocas fotos etiquetadas de la zona donde se vaya a usar, separadas de las de prueba; entrenar con fotos de campo de varias zonas, incluidas zonas cafetaleras del Perú, para que la clase sana se parezca a las hojas reales; agregar una opción para rechazar fotos muy distintas a las de entrenamiento; y probar métodos de interpretación pensados para Transformers.

CONTRIBUCIONES

Integrante	Tareas en las que participó
Alex Reynaldo Pomazón Solórzano	Todas las secciones del artículo: introducción, trabajos relacionados, metodología, resultados, discusión y conclusiones. Además, repositorio, diapositivas y demostración
Alexander André Chávez Cabana	Datos, aumento de datos, modelos, función de pérdida y entrenamiento. Apoyo en trabajos relacionados (arquitecturas) y en la revisión de las líneas base
Christian André Urviola García	Comparación con las líneas base, ablación y costo computacional. Apoyo en la reproducibilidad del entrenamiento y en la revisión de la metodología
Andhersson Manuel Salazar Fernández	Interpretación y análisis de errores (Grad-CAM y prueba de fondo), discusión, limitaciones y conclusiones. Apoyo en trabajos relacionados (enfermedades de plantas) y en la demostración

DISPONIBILIDAD DE CÓDIGO Y USO DE HERRAMIENTAS DE IA

El código, las configuraciones, los resultados y el notebook de demostración están en el repositorio (versión `v1.0-final`). Los pesos de los seis modelos de la semilla 0 están en una carpeta pública de Google Drive. Cada tabla y figura de este artículo se puede volver a generar con los comandos del README.

- Repositorio: https://github.com/pomazon/Examen_Final_Redes_Neuronales/tree/v1.0-final
- Pesos: https://drive.google.com/drive/folders/1fIOa7MGDJUeVh-MrOiGy6_5snuy5TeF6

Usamos Claude (Anthropic) como asistente en estos puntos:

1. *Código.* Apoyó a escribir y depurar los scripts de preparación de datos, entrenamiento, evaluación e interpretación, el notebook de demostración en Colab y la aplicación web que usamos en la exposición.
2. *Orientación de los pasos.* Sugirió cómo ordenar el trabajo y qué técnicas aplicar en cada etapa: partición por bloques, detección de fotos casi iguales, cambio de fondo, líneas base y métricas.
3. *Redacción y forma.* El equipo armó la documentación del proyecto; el asistente ayudó a ordenarla y a darle forma de artículo IEEE, y a preparar las diapositivas.

Los integrantes del grupo ejecutaron todos los experimentos, revisaron que cada cifra del artículo coincida con los resultados obtenidos, interpretaron esos resultados y sacaron las conclusiones.

REFERENCIAS

[1] J. Avelino, M. Cristancho, S. Georgiou, P. Imbach, L. Aguilar, G. Bornemann, P. Läderach, F. Anzueto, A. J. Hruska, and C. Morales, "The coffee rust crises in Colombia and Central America (2008–2013): impacts, plausible causes and proposed solutions," *Food Security*, vol. 7, no. 2, pp. 303–321, 2015, doi: 10.1007/s12571-015-0446-9.

[2] S. P. Mohanty, D. P. Hughes, and M. Salathé, "Using deep learning for image-based plant disease detection," *Frontiers in Plant Science*, vol. 7, p. 1419, 2016, doi: 10.3389/fpls.2016.01419.

[3] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, and F. A. Wichmann, "Shortcut learning in deep neural networks," *Nature Machine Intelligence*, vol. 2, no. 11, pp. 665–673, 2020, doi: 10.1038/s42256-020-00257-z.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.

[5] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2021, doi: 10.48550/arXiv.2010.11929.

[6] W. Benabbas, M. Brahimi, S. Akhrouf, and B. Fortas, "Rethinking plant disease diagnosis: Bridging the academic-practical gap with vision transformers and zero-shot learning," arXiv:2511.18989, 2025, doi: 10.48550/arXiv.2511.18989.

[7] J. G. M. Esgario, R. A. Krohling, and J. A. Ventura, "Deep learning for classification and severity estimation of coffee leaf biotic stress," *Computers and Electronics in Agriculture*, vol. 169, p. 105162, 2020, doi: 10.1016/j.compag.2019.105162.

[8] J. C. Santa-María and C. Rodríguez, "Automatic detection of coffee leaf diseases through pattern recognition," *Revista Científica de Sistemas e Informática*, vol. 6, no. 1, p. e1349, 2026, doi: 10.51252/rcsi.v6i1.1349.

[9] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, doi: 10.1109/ICCV.2017.74.

[10] J. C. Santa Maria Pinedo, "Coffee leaf dataset by phytosanitary class," Mendeley Data, versión 2, 2026, doi: 10.17632/mfpxg4y65r.2.

[11] J. Parraga-Alava, K. Cusme, A. Loor, and E. Santander, "RoCoLe: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition," *Data in Brief*, vol. 25, p. 104414, 2019, doi: 10.1016/j.dib.2019.104414.

[12] S. Chelangat, R. Anirwoth, K. N. Mayanja, and A. Sserwadda, "A machine learning dataset for classification of common coffee leaf diseases in Uganda," Mendeley Data, versión 1, 2025, doi: 10.17632/k36wnd6knb.1.